

PRÀCTICA DE CERCA LOCAL
Intel·ligència Artificial
2025-26

Damià Muñoz, Júlia Castellote, Santiago Lluzar

ÍNDIX

1. El Problema

- 1.1. L'enunciat**
- 1.2. Descripció de la implementació de l'estat**
- 1.3. Descripció dels operadors escollits**
- 1.4. Generació de les solucions inicials**
- 1.5. Funció heurística**

2. Experiments

- 2.1. Experiment 1: Selecció del Millor Conjunt d'Operadors**
- 2.2. Experiment 2: Selecció de la Millor Solució Inicial**
- 2.3. Experiment 3: Ajust de Paràmetres de Simulated Annealing**
- 2.4. Experiment 4: Anàlisi d'Escalabilitat (HC vs. SA)**
- 2.5. Experiment 5: Impacte de la Distribució de Centres**
- 2.6. Experiment 6: Influència del Cost per Quilòmetre**
- 2.7. Experiment 7: Influència del Límit de Quilòmetres (kmMax)**
- 2.8. Experiment 8: Execució Específica amb Millors Configuracions**

3. Conclusions Generals

4. Treball d'Innovació: Whisper

- 4.1. Breu descripció**
- 4.2. Repartiment del treball**
- 4.3. Referències**

1. El problema

1.1. L'enunciat

El problema ens presenta una companyia que disposa de n centres de distribució repartits estratègicament dins una àrea geogràfica de 100×100 km². Cada centre té un camió cisterna assignat que transporta combustible a les gasolineres que ho requereixin.

La distància entre un centre D i una gasolinera G es calcula mitjançant la distància de Manhattan:

$$d(D, G) = |D_x - G_x| + |D_y - G_y|$$

Les gasolineres, per la seva banda, generen peticions de subministrament a mesura que els seus dipòsits es van buidant, i és possible que una mateixa gasolinera acumuli diverses peticions pendents alhora. Cada camió cisterna pot omplir completament dos dipòsits.

Un viatge consisteix en un camió que parteix del seu centre de distribució, omple la seva cisterna, serveix dues peticions com a màxim i torna al centre.

Les peticions no ateses en un dia s'acumulen, i el seu valor denota els dies que porta pendent, cosa que afecta a la rendibilitat del servei. Depenent dels dies que porta acumulada una petició, la companyia rebaixa el preu que cobra pel combustible. El percentatge de preu que es cobra segueix la fórmula:

$$\%preu = (100 - 2^{dies})\%$$

L'objectiu és trobar per a un dia l'assignació de peticions a cisternes i com les serviran, de manera que s'obtingui el benefici més gran, però minimitzant el que es perdrà amb les peticions no ateses i que la distància recorreguda sigui la menor possible.

Restriccions:

- Cada cisterna podrà recórrer màxim 640 km diaris.
- Una cisterna no pot fer més de 5 viatges diaris.
- Assumim que el valor d'un dipòsit és de 1000
- El cost per quilòmetre és 2.

1.2. Descripció de la implementació de l'estat

Aquesta pràctica es resol mitjançant algorismes de cerca local, una metodologia on, a partir d'una solució inicial qualsevol, s'exploren solucions veïnes cercant millores iteratives. Per tant, un estat representa una solució del problema, així que la classe està dissenyada per contenir tota la informació que defineix una assignació de rutes i per facilitar l'aplicació eficient dels operadors de cerca.

La implementació de l'estat es compon de dues categories de dades: les estàtiques (*static*), que defineixen el problema i les no estàtiques, que defineixen una solució concreta.

Les estàtiques es declaren d'aquesta manera per tal d'obtenir un millor rendiment, ja que només s'inicialitzen una vegada i es redueix significativament el consum de memòria.

La primera proposta de dada estàtica va ser crear una matriu 100x100 ja que l'enunciat esmenta que l'àrea geogràfica ocupa 100 x 100 km², on s'indicarien totes les gasolineres i centres de distribució. A causa del gran cost temporal que costaria accedir a aquesta matriu i el cost espacial que també representa, no es va implementar.

En conseqüència, va semblar una millor opció crear dues matrius:

- *distCentresGasolineres*[][] : aquesta matriu és $n \times p$ (sent n el nombre de centres de distribució i p el nombre de gasolineres definits) i cada casella representa la distància entre un centre i amb una gasolinera j .
- *distGasolineres*[][] : aquesta matriu és $n \times n$ i cada casella representa la distància entre un centre i amb un centre j . La diagonal tindrà valor zero.

Una altra variable static és el array de Gasolineres *peticions_totals*, que conté totes les peticions individuals que s'han de servir. A la funció constructora de l'estat les Gasolineres amb múltiples peticions es descomponen en objectes Gasolinera individuals per a cada petició.

Finalment, s'ha declarat un array de Centros (CentrosDistribucion) *centres_dist*, que emmagatzema la informació dels centres de distribució.

S'han creat tres estructures no estàtiques: *rutes*, *distancias* i *peticions_no_ateses*.

El mapa *rutes* té com a clau els centres de distribució i com a valor un array de gasolineres. Per tant, s'associa cada camió amb la seva ruta assignada, la qual és una llista de peticions a servir.

L'altre mapa *distancias* conté com a clau els centres de distribució i com a valor un enter amb la distància total recorreguda del camió corresponent, d'aquesta manera s'evita recalcular aquest valor cada cop que s'avalua un estat.

Finalment, l'array de gasolineres *peticions_no_ateses* conté la llista de peticions no assignades a cap camió.

1.3. Descripció dels operadors escollits

Els operadors de cerca són els que ens permeten canviar d'estat. Determinen la capacitat de l'algorisme per explorar l'espai de solucions de manera eficient.

S'han implementat tres operadors:

Afegir petició:

- **Paràmetres:**
 - *centreDist*: instància del centre de distribució.
 - *indexPeticio*: L'índex de la petició dins de la llista de *peticions_no_ateses*.
- **Precondicions:**

El centre de distribució existeix, i si existeix ha d'atendre menys de 10 peticions.
L'índex és un valor entre 0 i la mida del vector *peticions_no_ateses*.
- **Postcondicions:**

S'afegeix la petició corresponent a l'índex al centre *centreDist*.
- **Factor de ramificació:**

Si tenim n centres i pn peticions no ateses, com es pot afegir qualsevol petició a qualsevol centre, el factor de ramificació és $O(n \cdot pn)$.

Eliminar petició:

- **Paràmetres:**
 - *centreDist*: instància del centre de distribució.
 - *indexPeticio*: índex d'una de les peticions ateses *indexPeticio* pel centre (trobat al mapa *ruta*).
- **Precondicions:**

centreDist existeix i l'índex està comprès entre les peticions ateses.
- **Postcondicions:**

S'elimina la petició atesa pel centre i s'afegeix a *peticions_no_ateses*.
- **Factor de ramificació:**

Si tenim n centres i com a màxim es poden tenir 10 peticions ateses, el factor de ramificació és $O(n \cdot 10)$.

Swap de peticions:

- **Paràmetres:**
 - *centre1* i *centre2*: instància de centres de distribució.
 - *index1* i *index2*: índexs de peticions ateses de cada centre, respectivament.

- **Precondicions:**
 $centre1$ i $centre2$ existeixen i els índexs estan compresos entre les peticions ateses de cada centre respectivament.
- **Postcondicions:**
 S'intercanvien les peticions definides per cada índex entre els dos centres.
- **Factor de ramificació:**
 Si tenim n centres i cadascun com a màxim té 10 peticions ateses, el factor de ramificació és $O(n^2 \cdot 10^2)$.

1.4. Generació de les solucions inicials:

L'eficiència de l'algorisme de cerca local està condicionada per la qualitat del seu punt de partida. En aquesta pràctica s'han generat tres estats inicials:

Estat inicial buit:

Aquesta estratègia consisteix a generar la solució de partida de la manera més simple: el sistema es configura amb el tauler completament buit, sense que cap centre de distribució tingui assignada cap petició de subministrament. De manera que la llista de peticions no ateses conté la totalitat de les peticions del dia. Les distàncies totals acumulades són 0 per a tots els centres igual que els beneficis obtinguts.

L'avantatge principal d'aquest estat inicial és com es relaciona amb el Hill Climbing, ja que en iniciar desde zero, es comporta de manera similar a un algorisme voraç, on a cada pas, seleccionarà l'acció d'afegir la petició que maximitza de forma immediata l'heurística. D'aquesta manera es construirà una solució de manera seqüencial fins a assolir un òptim local

Estat inicial Aleatori:

Aquesta estratègia genera una solució inicial mitjançant un repartiment aleatori de les tasques. La seva lògica consisteix a desordenar completament el conjunt total de peticions i, a continuació, distribuir-les de la manera més equitativa possible entre els diferents camions. D'aquesta manera es crea un punt de partida imprevisible a cada execució.

El seu avantatge és que garanteix que el seu punt de partida és completament diferent en cada execució, cosa que augmenta la probabilitat de trobar òptims locals i ajuda a evitar que l'algorisme quedi atrapat repetidament en el mateix òptim local com podria passar als altres estats inicials.

Estat inicial de mínima distància entre peticions i Centres:

Aquesta estratègia genera una solució inicial heurística i constructiva basada en el criteri de mínima distància. S'assigna cada petició al centre de distribució que la tingui més a prop, sempre que

l'assignació no incompleixi la restricció de quilometratge màxim del camió. Aquesta solució requereix més temps de càlcul inicial perquè per a cada petició s'ha de recórrer la llista de centres de distribució ($O(p * n)$ on $p = \text{peticions totals}$).

L'avantatge d'aquest estat inicial rau en la seva qualitat de partida. Es parteix d'un punt de l'espai de cerca molt millor que el punt buit, ja que optimitza un dels criteris de l'heurística: la minimització de la distància total.

1.5. Funció heurística:

La funció heurística està dissenyada per complir l'objectiu real del negoci, que es tenir una bona rendibilitat diària. La nostra heurística es compon de dues parts: El cost del transport i els beneficis.

El cost del transport es calcula amb la distància total recorreguda dels camions i es multiplica per un factor de cost, que és 2. Com més llarga sigui la ruta, més gran serà l'heurística i, per tant, pitjor serà.

Benefici de les Peticions Ateses: Es calcula sumant els ingressos generats només per les peticions que s'han assignat a les rutes dels camió. El valor de cada petició depèn dels dies que porta pendent, aplicant la fórmula que penalitza les peticions més sobre un valor base de 1000.

Per tant, el valor que s'obté de l'heurística surt de la resta del cost menys els beneficis. D'aquesta manera, l'objectiu dels algorismes emprats de cerca local és minimitzar el valor retornat per la funció heurística. La nostra funció heurística es calcula com:

$$\text{Heurística} = (\text{distanciaTotal} * 2) - \text{beneficiTotalAteses}$$

És important destacar que, en la implementació de la funció heurística, les peticions no ateses no contribueixen directament al valor heurístic. L'heurística se centra exclusivament en el balanç entre el cost del transport i el benefici obtingut per les peticions que sí s'han assignat a les rutes. No s'inclou una penalització explícita per les peticions que queden a la llista `peticions_no_ateses`, ni tampoc una estimació del benefici futur que podrien generar si s'atenguessin l'endemà. Això ajuda a simplificar el càlcul de l'heurística i a fer que l'avaluació de cada estat sigui més ràpida

2. Experiments:

Experiment 1

Aquest experiment té com a objectiu determinar quin conjunt d'operadors de cerca (Afegir, Eliminar, Swap) proporciona els millors resultats amb l'algorisme Hill Climbing (HC). L'objectiu és fixar el conjunt d'operadors més efectiu i eficient per a la resta d'experiments de la pràctica.

Observació:

L'eficàcia d'un operador es mesura per la seva capacitat de conduir l'estat cap a un òptim local amb la millor avaluació heurística. Atès que HC sempre tria el successor que proporciona la màxima millora heurística(amb valor absolut), la combinació d'operadors afecta directament la qualitat i la rapidesa amb què es troba l'òptim.

Plantejament:

Es comproven quatre combinacions lògiques d'operadors i s'avalua la qualitat de l'heurística:

- Afegir+Swap
- Afegir
- Afegir+Eliminar
- Tots junts

S'han triat només aquestes combinacions, ja que són les úniques que tenen sentit. Per cada combinació s'han dut a terme 10 proves amb seeds diferents.

Hipòtesi:

Assumim que la inclusió dels operadors de moviment (Swap) i/o eliminació (Eliminar) hauria de permetre a l'algorisme explorar millor l'espai de cerca, alliberant rutes d'assignacions subòptimes i, per tant, millorar la qualitat de l'heurística final obtinguda en comparació amb l'ús exclusiu de l'operador Afegir.


Metodologia:

- **Escenari:** S'utilitza l'escenari base del problema: 10 centres de distribució, amb 1 camió per centre, i 100 gasolineres.
- **Algorisme:** Hill-Climbing.
- **Estat inicial:** Buit, aleatori i mínima distància entre peticions i Centres.
- **Repeticions:** Es fan 10 proves per a cada combinació, fent servir "seeds" diferents, i es calculen els valors mitjans.


Resultats:

En els gràfics següents es poden veure els resultats:

Temps d'Execució Mitjà per Combinació



Qualitat de la Solució (Heurística Final Mitjana)



Conclusions:

S'observa que tant Afegir+Swap i Totes juntes tenen la mateixa heurística, cosa que indica que Eliminar no influeix directament. S'observa també que el temps d'execució en Totes Juntes es superior. Per tant Afegir + Swap és la millor combinació.

Experiment 2

Aquest experiment té com a finalitat determinar quina de les estratègies de generació de la solució inicial (Buit, Aleatori o Per Proximitat) proporciona els millors resultats. Un cop fixada la millor estratègia, aquesta s'utilitzarà per a la resta d'experiments de la pràctica.

Observació:

No totes les solucions inicials donen els mateixos resultats. L'eficàcia d'una estratègia d'inicialització no depèn només de la seva qualitat inicial, sinó de com aquesta afecta el camí de cerca de l'algorisme Hill Climbing.

Plantejament:

Es comparen els resultats d'aplicar l'algorisme Hill Climbing amb els operadors fixats (Afegir + Swap) a partir de les tres estratègies d'inicialització: Buit, Aleatori i Per Proximitat.


Hipòtesi:


Opinem que l'estat Per Proximitat hauria d'obtenir una bona heurística per la seva proximitat inicial a un òptim de cost, o ser el més ràpid.

Metodologia:

- **Escenari:** Es fa servir l'escenari base: 10 centres de distribució, 1 camió per centre, i 100 gasolineres.
- **Algorisme i operadors:** S'utilitza l'algorisme Hill Climbing amb els operadors fixats a l'Experiment 1: Afegir + Swap.
- **Repeticions.** Es fan 10 proves per a cada estratègia d'inicialització, calculant els valors mitjans de l'heurística final.

Resultats:





Conclusions:

L'Estat Buit és l'estratègia més efectiva. La seva capacitat per obligar al Hill Climbing a actuar de manera voraç, construint la solució des de zero, permet trobar un òptim local que supera la qualitat de les solucions inicials més elaborades.

Experiment 3

Aquest experiment té com a finalitat determinar combinacions òptimes de valors per als paràmetres k (probabilitat d'acceptar solucions pitjors), λ (refredament) i $stiter$ (iteracions x refredament) de l'algorisme Simulated Annealing, per poder així obtenir el millor rendiment. Per simplificar càlculs de combinacions sempre treballarem amb temperatura inicial de 1500.

Observació:

Els diferents valors d'aquests paràmetres influeixen directament sobre el comportament de l'algorisme de Simulated Annealing.

Plantejament:


S'avaluen un conjunt de valors per a cada paràmetre i es proven totes les combinacions per trobar la que conté un heurístic mitjà superior.

Hipòtesi:

S'assumeix que valors intermedis o alts de k (1000–2000) permeten explorar millor l'espai de solucions sense perdre estabilitat; que valors baixos de λ (0.001–0.0001) afavoreixen un refredament més lent i una convergència més precisa; i que $stiter$ elevats (400–500) ofereixen més oportunitats de millora a cada temperatura, obtenint així una heurística mitjana superior.

Metodologia:

- **Escenari:** S'utilitza l'escenari base: 10 centres de distribució, 1 camió per centre, i 100 gasolineres.
- **Algorisme:** Es treballa amb l'algorisme de Simulated Annealing.
- **Paràmetres a avaluar:**
 - k : 10, 100, 500, 1000, 1500, 2000, 5000
 - λ : 1.0, 0.1, 0.01, 0.001, 0.0001
 - $stiter$: 50, 100, 125, 200, 250, 400, 500
- **Repeticions:** cada combinació s'executa 10 cops. En total es fan 2450 proves.
- **Càlcul:** mesurem la mitjana de l'heurística de cada combinació.
- **Avaluació:** es busca mitjana màxima entre totes les combinacions provades.



Conclusions:

En els resultats s'ha observat que la millor combinació stiter mitjà és de 400, la k de 1500 i la lambda de 0.0001 amb una heurística mitjana de -92494. A partir d'aquests valors es construeix un gràfic 3D en què apareixen els diferents valors de lambda, k i l'heurística donat el stiter de 400. Com a conclusió, es té els valors òptims de l'algorisme de Simulated Annealing.

Experiment 4

Aquest experiment estudia com evoluciona el temps d'execució de la cerca i la qualitat de la solució per als algorismes Hill Climbing i Simulated Annealing a mesura que s'incrementa la grandària del problema, mantenint la proporció fixada entre centres i gasolineres.

Observació:

L'escalat del problema afecta dramàticament el factor de ramificació i l'espai de cerca.

Plantejament:

Es compara el temps d'execució i la qualitat de solució (heurística) de HC i SA en valors creixents del problema, mantenint la proporció 10 centres: 100 gasolineres (x10).


Hipòtesi:

- **Hill Climbing (HC):** El temps d'execució creixerà ràpidament (exponencialment) a causa de la gran càrrega de generar i avaluar tots els successors en cada pas (factor de ramificació elevat).
- **Simulated Annealing (SA):** El temps d'execució serà més estable, ja que només genera un successor aleatori per pas, mantenint la complexitat constant respecte a l'espai de cerca.

Metodologia:

- **Escenari:** S'incrementa l'escala de 10:100 fins que es vegi la tendència.
- **Algorisme i operadors:** S'utilitzen Hill Climbing i Simulated Annealing amb els operadors fixats a l'Experiment 1: Afegir + Swap.
- **Repeticions.** Es realitzarà una execució única per a cada mida pel fet que el temps d'execució arriba a valors massa elevats.

Resultats:



Conclusions:

El Simulated Annealing és l'algorisme clarament superior pel que fa a l'escalabilitat i l'eficiència temporal. Tot i que Hill Climbing pot ser més ràpid en els problemes petits (10:100), esdevé inviable en qüestions de temps (i memòria) en les escales grans.

Experiment 5

L'objectiu d'aquest experiment és analitzar com varia el rendiment si es manté constant el nombre total de camions, però es redueix a la meitat el nombre de centres.

Observació:

El nombre de camions a nivell pràctic serà el mateix, es compliran com a màxim el mateix nombre de peticions.

Plantejament:

Es compara la distància recorreguda i el benefici entre dos escenaris de 100 gasolineres, 10 camions, però un té 5 centres i l'altre 10.


Hipòtesi:


La reducció del nombre de centres de distribució provocarà un augment de la distància recorreguda, ja que la distància mitjana des d'un centre a qualsevol gasolinera augmentarà. El benefici disminuirà a causa de l'increment de quilòmetres recorreguts. El nombre de peticions ateses es mantindrà.

Metodologia:

- **Escenari:** 10 centres i 5 centres. 1 i 2 camions per centre, respectivament. 100 gasolineres.
- **Algorisme i operadors:** Hill Climbing amb els operadors "Afegir" + "Swap".
- **Repeticions:** S'executa el programa 100 vegades amb seeds aleatòries.

Resultats:





Conclusions:

L'anàlisi comparativa dels escenaris 10 centres, 1 camió/centre i 5 centres, 2 camions/centre ens revela resultats contradictoris que s'expliquen amb la gestió de les claus al HashMap utilitzat per emmagatzemar les rutes i les distàncies.

Contràriament a la hipòtesi inicial, que predeia un augment dels quilòmetres recorreguts a l'escenari 5 centres degut a una menor cobertura dels centres, les dades mostren una gran reducció tant dels quilòmetres recorreguts (mitjana ≈ 1195 km vs. ≈ 2735 km) com del benefici (mitjana 47700 vs 94000), així com un augment molt significatiu de les peticions no ateses (mitjana 75 vs 26).

El motiu, vist fent debugging, és que la llibreria IA.Gasolina proporciona referències idèntiques als objectes Distribucion que representen els diferents camions assignats a un mateix centre. Com la implementació per defecte de equals() i hashCode() es basa en la identitat de la referència, el HashMap tracta aquests objectes duplicats com una única clau. Això provoca una col·lisió de claus, on només s'acaba guardant una entrada (ruta i distància) per cada coordenada de centre.

Per tant, a l'escenari de 5 camions, l'estructura de dades només gestiona un. Aquesta reducció del nombre de camions explica la disminució del benefici i dels quilòmetres, així com l'augment de les peticions no servides. En conclusió, l'experiment no compara realment dos distribucions de 10 camions, sinó un escenari de 10 camions amb un de 5 camions, invalidant la premissa inicial de la comparació però revelant un error en el nostre plantejament.

Experiment 6

Aquest experiment estudia com l'increment del cost per quilòmetre afecta la solució trobada per Hill Climbing, especialment pel que fa al nombre de peticions servides i la seva distribució segons els dies pendents.

Observació:

Incrementar el cost del transport hauria d'influir en les decisions de l'algorisme sobre quines rutes són rendibles.

Plantejament:

S'executarà l'algorisme Hill Climbing per a diferents valors del cost per quilòmetre (començant per 2 i doblant-lo successivament). Es mesurarà el nombre de peticions ateses i la seva distribució per dies pendents per observar la tendència.


Hipòtesi:


S'espera que a mesura que augmenta el cost per quilòmetre, l'algorisme prioritzi menys les peticions llunyanes o menys rendibles (les que porten més dies pendents), provocant un menor nombre total de peticions servides i un canvi en la proporció de peticions servides segons els dies que duen pendents.

Metodologia:

- **Escenari:** 10 centres, 100 gasolineres, estat inicial BUIT.
- **Algorisme i operadors:** Hill Climbing amb els operadors "Afegir" + "Swap".
- **Repeticions.** S'executa el programa 100 vegades amb seeds random per a cada cost per quilòmetre, començant per 2 i doblant-lo a cada pas (2, 4, 8, 16, 32).

Resultats:





Conclusions:

Heurística i Benefici: Com era d'esperar, l'augment del cost per quilòmetre provoca una disminució significativa de l'heurística final (valors menys negatius) i, per tant, una reducció del benefici net.

Peticions Servides: Sorprenentment, el nombre total de peticions servides i la proporció d'aquestes segons els dies pendents es mantenen pràcticament constants a través dels diferents costos per quilòmetre provats. No s'observa la tendència esperada de deixar més peticions sense atendre a mesura que el transport s'encareix.

Experiment 7

Aquest experiment analitza com la variació dels quilòmetres màxims diaris permesos (kmMax), que és una conseqüència directa de l'horari de treball, afecta el benefici final obtingut per l'algorisme Hill Climbing, mantenint constant el límit de 5 viatges diaris.

Observació:

El límit de quilòmetres diaris (kmMax) podria restringir la capacitat de l'algorisme per trobar solucions més rendibles, ja que pot impedir realitzar rutes més llargues però beneficioses.

Plantejament:

S'executarà l'algorisme Hill Climbing per a diferents valors de kmMax, corresponents a diferents hores de treball (des de menys de 8 h fins a un nombre elevat com 20 h). Es mesurarà el benefici final obtingut per a cada valor de kmMax per observar la progressió.


Hipòtesi:

S'espera que augmentar kmMax permeti a l'algorisme trobar solucions amb un benefici superior, ja que tindrà més flexibilitat per dissenyar rutes. Tanmateix, s'hipotetitza que aquest augment de benefici arribarà a un punt de saturació on incrementar kmMax ja no suposarà cap millora significativa.

Metodologia:

- **Escenari:** 10 centres, 100 gasolineres, inici BUIT.
- **Algorisme i operadors:** Hill Climbing amb els operadors "Afegir" + "Swap".
- **Repeticions.** Per a cada valor de kmMax de la llista {560, 640, 720, 800, 880, 960, 1120, 1280, 1440, 1600} s'executa el programa 40 vegades, utilitzant seeds aleatòries.

Resultats:



Conclusions:

L'anàlisi dels resultats permet confirmar la hipòtesi del punt de saturació. Es pot determinar a partir del valor 800 kmMax (o 10 hores de treball) ja no s'obté una millora significativa en el benefici, probablement perquè l'algorisme ja pot fer els 5 viatges més rendibles dins d'aquest límit de quilometratge. Això indica que, més enllà d'aquest punt, la restricció limitant no són els quilòmetres sinó el nombre de viatges permesos .

Experiment 8

Aquest experiment té com a objectiu obtenir un resultat per a un escenari específic, utilitzant les millors configuracions (operadors i inicialització) determinades als experiments anteriors.

Plantejament:

S'executarà l'algorisme Hill Climbing sota les condicions especificades (seed 1234, escenari 10c / 1t / 100g, operadors fixats a l'Exp 1, inicialització fixada a l'Exp 2).

Metodologia:

- **Escenari:** 10 centres, 1 camió per centre, 100 gasolineres, inici BUIT, seed = 1234.
- **Algorisme i operadors:** Hill Climbing i Simulated Annealing amb els operadors "Afegir" + "Swap".
- **Repeticions.** S'executa el programa 1 vegada.

Hill Climbing:

Cerca completada en: 3642 ms

nodesExpanded : 111

Heurística final: -93456.0

Peticions no ateses: 26

Simulated Annealing:

Cerca completada en: 21 ms

nodesExpanded : 401

Heurística final: -70140.0

Peticions no ateses: 43

3. Conclusions:

La realització d'aquesta pràctica ens ha proporcionat una millor comprensió dels algorismes de Hill Climbing i Simulated Annealing. Hem vist la seva utilitat per resoldre problemes d'optimització complexos.

S'ha observat experimentalment que, amb un ajust adequat dels paràmetres (k , λ , α), Simulated Annealing té la capacitat d'escapar òptims locals on Hill Climbing pot quedar atrapat, arribant a solucions de major qualitat. A més, en escenaris de major magnitud (Experiment 4), s'ha vist que SA pot obtenir solucions de qualitat comparable a HC en menys temps d'execució, tot i que el temps de HC creix més ràpidament.

Com a dificultat significativa, durant l'Experiment 5 es va descobrir que la implementació inicial de l'estat, utilitzant HashMap, no gestionava correctament el cas de múltiples camions per centre. Això era degut al fet que la llibreria IA.Gasolina proporcionava referències idèntiques per als camions d'un mateix centre, provocant col·lisions de claus al HashMap i fent que, a la pràctica, només es fer servir un camió per coordenada de centre. Això va invalidar la comparació directa de l'Experiment 5 tal com estava plantejat inicialment, però va servir per entendre una limitació important de l'enfocament i la interacció amb la llibreria proporcionada.

Més enllà dels algorismes, el desenvolupament de la pràctica ha permès millorar coneixements en Java, R (per a la visualització de resultats) i GitHub per a la documentació. També s'ha reforçat habilitats essencials com el treball coordinat en equip i el disseny i anàlisi d'experiments. Considerem que el funcionament intern del grup ha estat bo i estem satisfets amb el resultat final.

4. Treball d'Innovació:

Breu descripció:

Whisper és un sistema de reconeixement automàtic de veu desenvolupat per OpenAI que ofereix transcripció i traducció multilingüe. És un projecte de codi obert entrenat amb una gran quantitat d'àudio supervisat, per tant, reconeix i tradueix de forma fiable i flexible.

Repartiment del treball:

Tots tres ens dediquem a la investigació i descripció de les tècniques de IA utilitzades i la bibliografia i referències.

Individualment es farà:

- **Damià Muñoz:** Descripció de Whisper i descripció de com s'han utilitzat i adaptat les tècniques per la innovació.
- **Júlia Castellote:** Explicació de per què és un producte innovador i la naturalesa de la innovació.
- **Santiago Lluzar:** Impacte de la innovació feta al producte a l'empresa i en l'usuari o la societat.

Dificultats:

Encara que sigui open source, ens ha costat trobar informació sobre el model d'IA de Whisper ja que costa identificar fonts fiables.

Referències:

A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, i I. Sutskever, "Robust Speech Recognition via Large-Scale Weak Supervision," OpenAI, 2022.

[Consultat: 7-10-2025]. Apartats: Introducció i funcionament intern.

A. Andreyev, *Quantization for OpenAI's Whisper Models: A Comparative Analysis*, Independent Researcher, Washington, DC, United States, 2025.

[Consultat: 7-10-2025]. Apartat: 1. Introducció.

OpenAI, "Whisper," OpenAI. [En línia]. Disponible: <https://openai.com/es-ES/index/whisper/>.

[Consultat: 12-10-2025]. Apartat: Introducció a la IA.

K. Mahelona, G. Leoni, S. Duncan, and M. Thompson, "OpenAI's Whisper is another case study in Colonisation," Papa Reo, Jan. 24, 2023. [Online].Disponible: <https://blog.papareo.nz/whisper-is-another-case-study-in-colonisation/>
[Consultat: 26-09-2025] Apartat : Impacte a la societat.